

DATOS DEL INFORME

Informe número: 1

Fecha: 23/03/2026

DATOS DEL ESTUDIANTE

Nombre: Rubén

NP: 139174

Apellidos: Nogueras González

DATOS DEL TRABAJO

Título del TFM: Del Bit al
comportamiento:
Redefiniendo la frontera
de la seguridad mediante
el aprendizaje profundo

Código TFM: 139174

Director del TFM: Sara
Ignacio Cerrato

Progreso TFM (%): 30%

Tiempo hasta la finalización (en meses): 4

Firma del alumno:



NORMAS

1. El estudiante subirá este formulario correctamente cumplimentado a la tarea correspondiente, antes de la fecha límite establecida respetando la nomenclatura siguiente en el nombre del archivo:
CODIGOTFG_NP_Informe X.pdf
2. Además, el estudiante adjunta un segundo archivo PDF cuyo contenido servirá como evidencia del trabajo realizado hasta la fecha del informe. Se respetará la nomenclatura siguiente en el nombre del archivo:
CODIGOTFG_NP_Informe X_Evidencias.pdf
3. Una vez subidos ambos archivos el estudiante avisará a través de la mensajería del campus a su tutor para que este valide el informe.
4. El tutor validará el informe, introduciendo como puntuación del mismo el porcentaje del trabajo ya realizado, así como los comentarios que considere oportunos.

Metodología

La metodología para este proyecto se centra principalmente en la detección de ciberataques en el flujo de una red, mediante técnicas de aprendizaje no supervisado. Lo que se hace es analizar el flujo de una red de carácter legítimo, sin intenciones maliciosas, obteniendo métricas y datos muy diferentes del flujo de una red víctima de un ciberataque, para detectar dicho tráfico malévolo a través de una red neuronal. Hasta ahora, se han seguido los siguientes pasos:

- **Análisis y preprocesamiento:** El dataset utilizado para este trabajo es el *CICIDS2017*, el cual incluye tráfico normal de red y tráfico con intenciones maliciosas, como DoS, PortScan, fuerza bruta, inyecciones SQL, etc. En primer lugar se ha hecho un análisis de los datos para tener mayor contexto y posteriormente se ha realizado un preprocesamiento, eliminando variables redundantes o que no pueden ser replicables en tiempo real debido a las limitaciones de la librería *NFStream*.
- **Estandarización Estadística:** Se ha realizado un escalado de datos con *StandardScaler*, normalizando los datos en función de la media y la desviación típica, haciendo que el modelo sea muy sensible a valores atípicos, los cuales en muchos casos son claros ejemplos de tráfico malicioso.
- **Autoencoder:** Se ha diseñado una red neuronal con una estructura de compresión y descompresión. Lo que hace esta red es intentar replicar, siempre con cierto error, los datos de la capa de entrada en la capa de salida. De esta manera, si el tráfico es benigno el error será bajo ya que la red ha sido entrenada con datos benignos en su entrenamiento, y por el contrario al toparse con un flujo malicioso, la red no puede replicar los datos correctamente ya que el tráfico malicioso es ciertamente distinto de un flujo de red “normal”, y por lo tanto el error se dispara, detectando una posible brecha de seguridad.
- **Reconstrucción en Tiempo Real:** Posteriormente se analiza el flujo de red dirigido a un servidor web en local, preprocesando el flujo de datos para que tenga la misma estructura que los datos de entrenamiento del modelo, y posteriormente pasando dichos datos a la red para detectar tráfico malicioso en tiempo real.

Resultados y conclusiones hasta la fecha

Hasta ahora los resultados han sido lo que se esperaba, detectando tráfico malicioso en tiempo real. Esto es debido a que hemos construido un modelo con una buena calidad de datos y que nos informa correctamente cuando nuestro servidor está siendo atacado. De momento se ha probado que todo el sistema funciona correctamente con denegaciones de servicio DoS hacia el servidor web, disparándose el error cuadrático medio del modelo (MSE) en dichos casos y detectando la amenaza.

Plan de trabajo propuesto

Hasta este punto, tenemos mucho trabajo adelantado y una base sólida para afrontar los próximos pasos. Durante las próximas semanas, se plantea diseñar una web atractiva y sobre todo funcional para poder hacer más pruebas, ya que de momento se tiene la web por defecto de apache. Planeamos introducir campos de texto, formularios con contraseñas, y conexión a una base de datos para realizar otros tipos de ataques y ver el comportamiento del modelo y sus resultados.

Una vez se tenga esto se procederá a construir un modelo de clasificación para detectar el ciberataque en específico, mediante modelos de machine learning de clasificación clásicos como son el RandomForest o un modelo Boosting, ya que generalmente son los que mejor resultados han dado bajo mi experiencia. No obstante, siempre estamos abiertos a nuevas metodologías que optimicen la detección, y analizaremos los resultados de distintos modelos para dar un veredicto final.

Por último, se integrarán los resultados obtenidos con un servicio de mensajería para notificar la presencia del ataque y avisar al administrador del servidor. También se planea, aunque esto no está del todo claro a día de hoy, gestionar la respuesta del administrador para bloquear el ataque, restringiendo el acceso de la dirección IP del atacante hacia el servidor. Puede ser que esta gestión se haga a través de un modelo de IA generativa LLM, o mediante un código clásico que detecte la respuesta del administrador. Un flujo de ejemplo sería:

Alerta: ¡Posible ataque de DoS detectado!

Desea bloquear la dirección IP atacante: X.X.X.X ?

Respuesta: Sí

Bloqueando dirección IP.

Y con esto se bloquearía la IP atacante. Como digo esta última parte está muy abierta a posibles cambios, pero creo que la idea general se entiende. Con esto una buena documentación y siendo muy rigurosos con la redacción del trabajo, creo que puede ser un TFG muy práctico e interesante para aplicar los conocimientos que he adquirido a lo largo de la titulación y finalizar mi paso por el grado de la mejor manera posible.