

DATOS DEL INFORME

Informe
número: 2

Fecha: 28/05/2026

DATOS DEL ESTUDIANTE

Nombre: Rubén

NP: 139174

Apellidos: Nogueras González

DATOS DEL TRABAJO

Título del TFM: Del Bit al comportamiento: Redefiniendo la frontera de la seguridad mediante el aprendizaje profundo

Código TFM: GMAI-25076

Director del TFM: Sara Ignacio Cerrato

Progreso TFM
(%): 95%

Tiempo hasta la finalización (en meses): 1

Firma del alumno:



NORMAS

1. El estudiante subirá este formulario correctamente cumplimentado a la tarea correspondiente, antes de la fecha límite establecida respetando la nomenclatura siguiente en el nombre del archivo:
CODIGOTFG_NP_Informe X.pdf
2. Además, el estudiante adjunta un segundo archivo PDF cuyo contenido servirá como evidencia del trabajo realizado hasta la fecha del informe. Se respetará la nomenclatura siguiente en el nombre del archivo:
CODIGOTFG_NP_Informe X_Evidencias.pdf
3. Una vez subidos ambos archivos el estudiante avisará a través de la mensajería del campus a su tutor para que este valide el informe.
4. El tutor validará el informe, introduciendo como puntuación del mismo el porcentaje del trabajo ya realizado, así como los comentarios que considere oportunos.

Metodología

La metodología para este proyecto se centra principalmente en la detección de ciberataques en el flujo de una red, mediante técnicas de aprendizaje no supervisado. Lo que se hace es analizar el flujo de una red de carácter legítimo, sin intenciones maliciosas, obteniendo métricas y datos muy diferentes del flujo de una red víctima de un ciberataque, para detectar dicho tráfico malévolo a través de una red neuronal. Hasta ahora, se han seguido los siguientes pasos:

- **Análisis y preprocesamiento:** El dataset utilizado para este trabajo es el CICIDS2017, el cual incluye tráfico normal de red y tráfico con intenciones maliciosas, como DoS, PortScan, fuerza bruta, inyecciones SQL, etc. En primer lugar se ha hecho un análisis de los datos para tener mayor contexto y posteriormente se ha realizado un preprocesamiento, eliminando variables redundantes o que no pueden ser replicables en tiempo real debido a las limitaciones de la librería NFStream.
- **Estandarización Estadística:** Se ha realizado un escalado de datos con StandardScaler, normalizando los datos en función de la media y la desviación típica, haciendo que el modelo sea muy sensible a valores atípicos, los cuales en muchos casos son claros ejemplos de tráfico malicioso.
- **Autoencoder:** Se ha diseñado una red neuronal con una estructura de compresión y descompresión, lo que hace esta red es intentar replicar, siempre con cierto error, los datos de la capa de entrada en la capa de salida. De esta manera, si el tráfico es benigno el error será bajo ya que la red ha sido entrenada con datos benignos en su entrenamiento, y por el contrario al toparse con un flujo malicioso, la red no puede replicar los datos correctamente ya que el tráfico malicioso es ciertamente distinto de un flujo de red "normal", y por lo tanto el error se dispara, detectando una posible brecha de seguridad.
- **Reconstrucción en Tiempo Real:** Posteriormente se analiza el flujo de red dirigido a un servidor web en local, preprocesando el flujo de datos para que tenga la misma estructura que los datos de entrenamiento del modelo, y posteriormente pasando dichos datos a la red para detectar tráfico malicioso en tiempo real.

Resultados y conclusiones hasta la fecha

En este trabajo se ha cumplido perfectamente con el objetivo principal de este proyecto, el cual es la elaboración e implementación de una arquitectura híbrida para la detección de anomalías en el tráfico de red de un servicio en tiempo real. Durante el desarrollo, se ha demostrado la enorme potencia de la fusión de modelos de aprendizaje no supervisado (la red neuronal) y supervisado (el modelo de clasificación), ofreciendo un sistema de detección de intrusiones robusto y escalable ideal para proteger sistemas frente a ciberataques, como el servidor web empleado.

La red neuronal mencionada anteriormente permite la detección de flujos anómalos en función de su error de reconstrucción, ofreciendo un motor de detección muy robusto sin la necesidad de conocer exactamente el ataque o su firma a nivel de red, lo cual es fundamental en el paradigma actual de la ciberseguridad, ya que cada día los malware son mucho más potentes y cambiantes, infiltrándose en aquellos sistemas de detección que se basan en mediciones estáticas.

Por otra parte, la integración de un modelo de clasificación Random Forest tras la red neuronal es de enorme ayuda para conocer en mejor medida las intenciones del atacante. Con esto se converge hacia la naturaleza del ataque, añadiendo la posibilidad de bloquear la dirección IP atacante para mitigar la amenaza a través de la API de Telegram.

Plan de trabajo propuesto

El plan de trabajo propuesto se basa en una estructura híbrida de detección y respuesta ante ciberataques, diseñada para operar en tiempo real sobre un servidor web. Este plan se divide en cuatro etapas críticas que permiten transformar el tráfico de red bruto en información accionable para un administrador de seguridad:

1. **Ingesta y procesamiento de datos:** Se utiliza la librería `nfstream` para capturar el tráfico de red, extrayendo características relevantes (como número de paquetes y banderas TCP) que alimentan los modelos predictivos.
2. **Detección de anomalías:** Se emplea una red neuronal de tipo Autoencoder, entrenada exclusivamente con tráfico benigno. El modelo detecta amenazas basándose en un error de reconstrucción (MSE) elevado ante flujos desconocidos, lo que actúa como una señal de alerta temprana ante comportamientos anómalos.
3. **Clasificación y respuesta:** Una vez detectada la anomalía, un modelo Random Forest clasifica el tipo de ataque (como DoS, fuerza bruta o inyecciones SQL). Finalmente, el sistema se integra con la API de Telegram para notificar al administrador, quien puede aplicar contramedidas defensivas, como el bloqueo de la IP atacante, en tiempo real.

Esta metodología no solo garantiza la detección mediante aprendizaje no supervisado, sino que aporta interpretabilidad mediante la clasificación jerárquica de las amenazas y una capacidad de respuesta activa, todo ello validado mediante auditorías de seguridad controladas y el uso de datasets de referencia.